基于机器学习的音乐流行趋势预测

摘　要

本文研究的是使用随机森林回归模型，基于音乐平台的艺人信息和用户行为数据集对音乐流行趋势预测的研究。探究影响歌曲流行趋势的关键因素，预测播放量。让预测为音乐行业人员提供可靠的流行趋势数据支持，为平台优化资源分配，音乐人制定创作方向等。

问题一，要分析影响歌曲流行趋势的关键因素。选用统计分析和可视化分析方法来探索数据，从中得到显著相关的因素，挖掘潜在的规律，然后建立**随机森林模型**特征重要性筛选关键因素。先合并数据集进行数据清洗，发现缺失值和异常值，为确保后续分析可靠性，删除缺失值和异常值。将用户行为聚合统计构建特征，同时衍生时间特征，最后对特征进行编码处理。遍历分类特征，得到箱线图和均值对比图分析特征影响。计算特征相关性矩阵，得到下载量与播放量强相关。利用 ANOVA 检验验证特征显著性，语言以及发行时间较显著。数据标准化处理后，利用随机森林模型进行预测，训练好的模型进行评估，验证有一定的精度和广泛性，输出特征重要性得分，能得到**下载量和独立用户数是最重要的两个特征**。

问题二，在给定的条件下利用问题一的关键影响因素，选取艺人推广歌曲以最大化总预测播放量。利用问题一的随机森林模型预测所有歌曲的播放量，聚合艺人特征并筛选符合条件的艺人，构建艺人特征矩阵。建立**线性规划优化模型**，以最大化总预测播放量为目标函数，创建二进制变量决策艺人选择，设定题目的约束条件，利用线性规划求解器求解，并验证结果。**预测结果与随机森林预测对比有一致性体现模型合理性**。

问题三，需要构建预测模型对艺人未来 60 天每日播放量预测。处理数据时，合并用户行为数据和歌曲数据，按艺人和日期聚合了每日播放量、下载量和收藏量，并添加了艺人静态特征。**特征工程**阶段，提取时间特征，设计基于历史播放量的滞后特征和滑动窗口统计量，形成多维度特征体系。训练三个模型，基于梯度提升决策树的 **LightGBM** 与 **XGBoost**，以及专用于时序建模的 **LSTM 神经网络**。根据时间划分训练集和测试集，训练模型后通过比较三个模型在测试集上均方根误差（RMSE）和平均绝对误差（MAE），选择表现最佳的模型进行后续预测。**这里选定的 LightGBM 对每位艺人进行递归预测，使用预测值作为后续预测的输入特征**。最后输出每位艺人的预测播放量。

本文围绕音乐流行趋势预测，对其影响因素分析，优化推广策略以最大化播放量，预测艺人未来播放量，能够帮助平台合理分配资源，挖掘潜力艺人，为音乐人提供创作方向，提供数据驱动的决策支持。

关键词：随机森林 线性规划　特征工程　LightGBM　XGBoost　LSTM 神经网络

一、 问题重述

全球音乐平台日均产生海量用户行为数据，平台需要精准预测音乐流行趋势达到优化推荐算法、挖掘潜力一人、提升用户留存的目的。流行趋势预测帮助独立音乐人制定创作方向与推广策略；为平台优化资源分配，平衡商业价值与用户个性化需求；协助版权方预判市场偏好，降低风险。基于平台数据，通过数学建模探索数据驱动的流行趋势预测方法，为行业提供可落地的技术参考。

根据提供数据和实际情况，建立数学模型，解决以下问题：

1.音乐流行趋势影响因素分析与特征建模，基于艺人信息和用户行为数据，分析影响歌曲流行趋势的关键因素。

2.利用问题一的关键影响因素，制定平台在下一阶段的首页推荐策略，从候选一人中获取目标艺人进行推广，以此最大化未来 60 天的总播放量预测值。存在以下约束条件：

（1）推荐总数不超 50 个；

（2）艺人男（Gender=1）、女（Gender=2）推荐比例介于 1:1 至 2:1 之间；

（3）中文歌曲（Language=1）推荐数量不少于推荐总数的 40%，外语歌曲（Language ≥2 且 Language≠0）推荐数量不超过 50%；

（4）每位艺人最多推荐三首热门歌曲（历史播放量排序）

3.根据艺人在 2015 年 3 月 1 日至 2015 年 8 月 30 日之间的的用户行为历史记录，建立数学模型，预测艺人随后 2 个月，即输出每个艺人在 2015 年 9 月 1 日 - 10 月 30 日期间的每日播放量预测值的播放数据（艺人所有歌曲的日累计播放量），从而发掘艺人的发展潜力。

二、 问题分析

2.1 问题一的分析

问题一要求识别影响歌曲流行趋势的关键因素，提供了艺人信息和用户行为两个数据集。这需要我们整合关联两个数据集并清洗，包括处理缺失值与异常值，时间转换等。在大量的数据中挖掘关键因素，通过探索性数据分析和特征工程来处理数据。数据分析能采用统计学中的相关性分析，找出显著相关的特征；也可以可视化分析，直观对比特征，寻找潜在规律。利用 ANOVA 检验每个分类特征对播放量是否有显著差异。特征工程中构建多维度的特征，特征间属于非线性关系且为分类特征，可以使用随机森林模型，能评估特征重要性，量化因素的影响权重，找到关键影响因素。[1]

2.2 问题二的分析

问题二聚焦于优化推广策略，基于题目约束条件和数据特征建立了混合整数规划模型。从候选艺人当中选取目标进行推广，以最大化未来 60 天的播放量预测值。利用问题一的关键因素，先建立随机森林模型预测每首歌的播放量。由于业务约束，要提取艺人特征，先其计算关键指标，再筛选有效艺人，获取每位艺人 Top3 歌曲及其语种数量，作为特征并回艺人特征中。建立优化模型，为艺人创建二进制变量作决策变量，决定是否选择该艺人；最大化预测播放量为目标函数，结合约束包括推荐位总数、性别比例、语言比例和每个艺人歌曲上限。求解优化模型，输出推荐的艺人及其歌曲列表。[6]

2.3 问题三的分析

问题三要求基于 2015 年 3 月 1 日至 8 月 30 日的历史行为数据，预测每位艺人的每日播放量，这是基于时间序列的回归预测问题。建模要考虑艺人每日播放量遭受多种因素的影响，其中包括历史播放量、用户行为、时间等，通过特征工程转换成模型可处理的输入。添加艺人静态特征，构建时间特征和滞后特征和滑动窗口特征。在模型选择时，考虑到时间序列预测的复杂性，我们计划尝试多种模型，树模型 LightGBM 和 XGBoost，这些模型能够处理复杂的特征交互，并且对非线性关系有较好的捕捉能力。深度学习模型 LSTM（神经网络），特别适合处理时间序列数据，能够捕捉长期依赖关系。划分数据集，使用训练集训练三个模型 LightGBM、XGBoost、LSTM，并在测试集上评估。选择最优模型进行递归预测，最终输出结果。[2]

三、 模型假设

1.不受外部因素影响
2.数据填充有效性
3.非负性假设

四、 指数假设

指数	中文名称	公式	说明
R^2	决定系数	$R^2=1-\frac{\sum_{i=1}^{n}\left(y_i-\hat{y}_i\right)^2}{\sum_{i=1}^{n}\left(y_i-\bar{y}\right)^2}$	拟合程度，R^2 越靠近 1 越好
RMSE	均方根误差	$RMSE=\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i-\hat{y}_i\right)^2}$	平均误差的标准差，数值越小，模型精度越高
MAE	平均绝对误差	$MAE=\frac{1}{n}\sum_{i=1}^{n}\lvert y_i-\hat{y}_i\rvert$	平均误差，数值越小，模型预测越准确

五、 模型的建立与求解

5.1 问题一模型的建立与求解

5.1.1 模型的建立

数据来源于歌曲元数据和用户行为日志，根据 song_id 字段合并数据。查看数据集发现存在缺失值，转换时间格式后发现时间逻辑异常数据。异常判断的根据是时间转换后发行时间晚于记录时间。为了数据集完整且合理以及后续分析的可靠性，**删除缺失值和异常数据**。

数据处理完成后，进行特征构建。将用户行为分为播放，下载，收藏三个类型，聚合构建歌曲维度的行为统计特征，**播放次数、独立用户数、下载次数和收藏次数**，

去重后并回数据集。挖掘四个时间特征：发行季度、月份、星期、时间，对分类特征编码，遍历分类特征得到关于播放量的箱线图和柱状图，同时**检验分类特征对播放量的显著性影响**，如表 1 所示：

表 1 分类特征对播放量的影响

分类特征	P 值	影响
Language	0.0000	显著
Gender	0.0795	不显著
Publish_month	0.0000	显著
publish_quarter	0.0002	显著
Publish_weekly	0.0030	显著

由表可以看出，性别对播放量的影响不显著，语言、月份、季度、星期对播放量有显著影响，说明在不同的时间点中，播放量会随其改变而改变。

计算相关性矩阵，画出热力图。如图 1 所示。

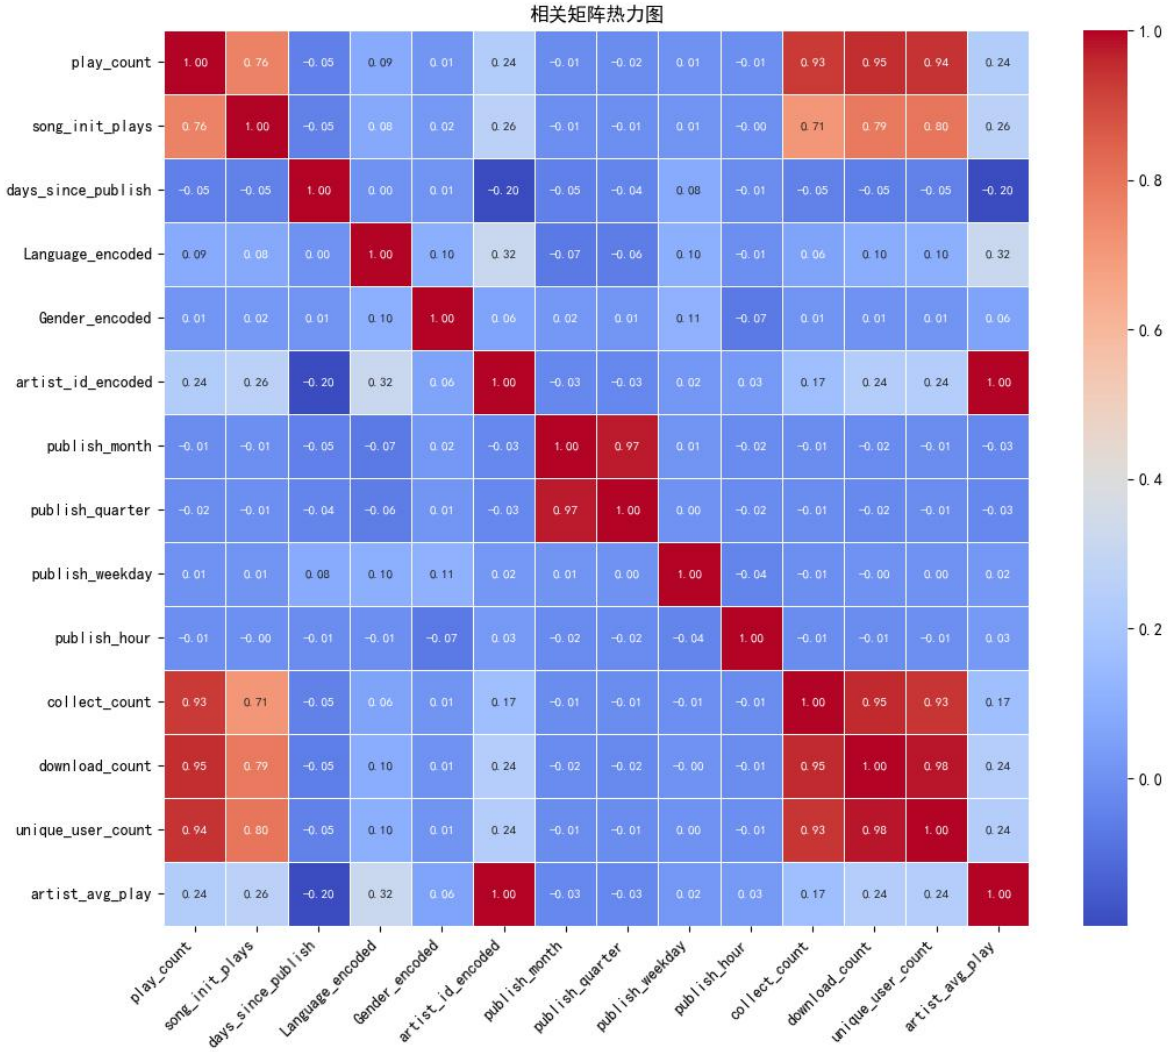


图 1 相关矩阵热力图

找到强关联的特征组，下载量与播放量相关系数达 **0.95**，独立用户与播放量相关系数 **0.94**。前者推断出**下载行为可能造成持续播放行为**，后者推测为**听众广泛程度是传播潜力的关键指标**。

对特征进行标准化，所有数值特征作标准化处理相处量纲影响。选择**建立随机森林回归算法**的预测模型，模型能够处理高维度特征并评估特征重要性。设定模型参数为 50 棵决策树和 15 层最大深度以防止过拟合，**将数据集按时间顺序划分训练集和测试集**，确保模型评估的客观性。

5.1.2 模型的求解

先将训练集在设定的随机森林模型中训练，再将测试集在训练好的模型中进行预测。同时计算三个关键指标：决定系数 R^2、均方根误差 RMSE 和平均绝对误差 MAE，能知道模型有良好的精度，同时具有优秀的泛化能力。在测试集上 RMSE=**0.4394** 说明预测值与实际值的平均偏差不足 **0.5** 个单位；MAE=**0.0177**，意味着平均预测误差仅 **2.7%**。这些指标综合证明模型具有优秀的预测精度和泛化能力。

表 2 模型评估指数

	R^2	RMSE	MAE
训练集	0.9897		
测试集	0.6258	0.4394	0.0177
评价	优秀	优秀	优秀

随机森林模型会自动评估特征重要性，生成由大到小特征重要性排序并做可视化处理，生成图 1。图 1 能直观出不同特征的重要性，其中下载量和独立用户数，两者共同决定了播放量 **90%**左右的预测能力。由此判断，**影响歌曲流行趋势的关键因素是下载量和独立用户数**。

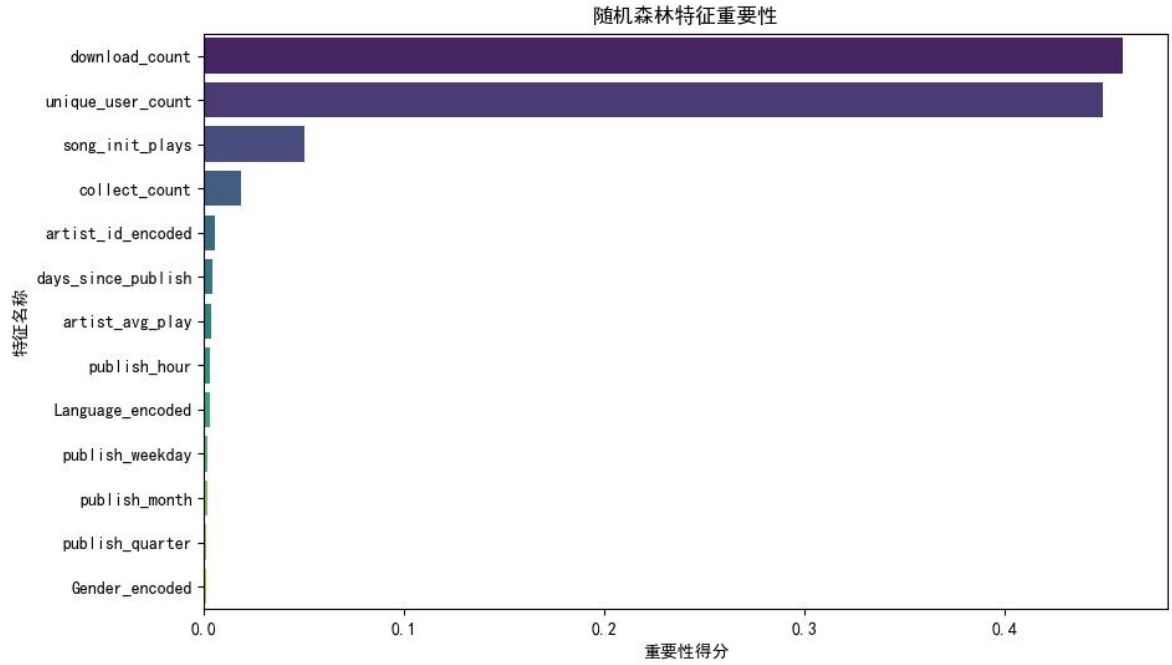


图 2 各特征重要性得分图

5.2 问题二模型的建立与求解

要在候选艺人中选取目标艺人进行推广，推广存在约束条件。使用问题一随机森林模型预测每首歌的播放量作特征列，聚合艺人特征，筛选符合约束条件的目标艺人。将播放量可视化直观了解那些歌曲或艺人具有高潜力，后续可验证预测模型的合理性。

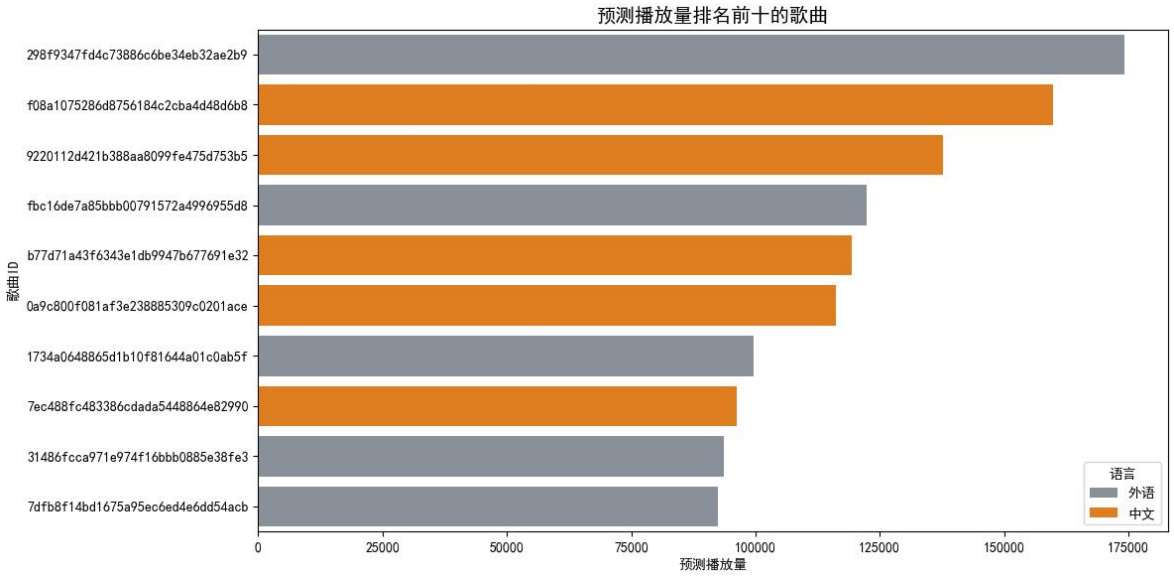


图 3 预测播放量前十的歌曲

获取每位艺人 Top3 的歌曲，对艺人分组按播放量排序，按照分组统计中文歌曲数量，外语歌曲数量和预测播放量之和，并回艺人特征表中。利用**线性规划模型**建立优化模型，以艺人特征创建二进制变量判断是否选择艺人，用目标函数进行最大化预测播放量。使用约束条件来确保艺人组合符合条件。设置了推荐总数约束，要求歌曲的总数不超过 50 ，接着是性别比例约束，通过计算男性艺人数量和女性艺人数量，要求二者比例在 1:1 到 2:1 之间，然后是语言约束，利用语言指标分别计算中文和外语歌曲数量，最后同一艺人不能超过三首歌。[3]

对优化模型进行求解，模型根据约束条件获取目标结果，再对结果进行验证是否符合约束条件。**能得出男艺人数量 13，女艺人数量 13，中文歌曲 39 首，外语歌曲 11 首，预测的播放量约为 2837920 的推荐结果**。输出推荐歌曲能发现优化模型中推广的艺人歌曲也在先前单独预测的播放量前十的名单，验证了该模型的合理性，并解释优化结果。同时使用线性规划求解器获取模型的求解结果状态，**输出为 Optimal 的求解状态，该状态表示模型已经找到最优解**。输出统计结果摘要，如图 4 所示。

统计指标	数值
总推荐艺人数量	26
总推荐歌曲数量	50
总预测播放量	2,837,919.5000000005
平均每首歌曲播放量	56,758
男艺人数量	13（50.0%）
女艺人数量	13（50.0%）
中文歌曲数量	39（78.0%）
外语歌曲数量	11（22.0%）

图 4 推荐结果统计

最后，我们将模型的结果，即推广的艺人及其歌曲保存在 csv 文件中。

5.3 问题三模型的建立与求解

整合两份原始数据，合并数据集后生成包含艺人、时间、用户行为的完整数据集。将日期字段转换为标准格式后，按艺人和日期聚合播放行为，计算每日播放量与唯一用户数，并补充下载、收藏等行为数据，形成多维度每日统计数据。添加艺人静态特

征和时间特征，通过时间特征工程提取日期周期性规律，创建滞后特征捕捉短期依赖，设计滑动窗口统计量反映近期趋势，并对分类属性进行标签编码。[5]按时间划分数据集，2015 年 3 月 1 日-2015 年 8 月 15 日作为训练集，2015 年 8 月 16 日-2015 年 8 月 30 日作为测试集。**将时间序列数据转换为监督学习数据，每个样本是一天，特征包括滞后特征、时间特征、艺人静态特征等，然后使用 LightGBM 和 XGBoost 进行训练。**

对于 LightGBM 模型，使用了 Optuna 进行超参数优化，从而使用最佳参数训练最终模型；对于 XGBoost 模型，通过修改 XGBoost 的模型参数，使其更符合数据集的训练；对于 LSTM 模型，需要重新准备不同的数据，按艺人分组并创建时间序列。这需要将每个艺人的时间序列单独处理，由于艺人数量多，且时间序列长度不同，我们需要对每个艺人构建固定长度的时间窗口作为输入，同时要确保有足够的数据创建序列。之后重塑数据以进行标准化，构建两层 LSTM 网络，使用 Dropout 减少过拟合，并设置回调函数，最后在测试集上训练。[4]对三个模型在测试集上评估，**计算 RMSE 和 MAE 比较模型性能，计算 R^2 比较模型预测精度**，如表 3 所示。

表 3 三个模型的评估指数

	RMSE	MAE	R^2
LightGBM	146.16	29.60	0.9903
XGBoost	180.74	31.90	0.9851
LSTM	207.65	96.69	0.9864

其中 LightGBM 对大误差和平均偏差的双重控制，以及接近于完美的精度，是当前最适合播放量预测的模型。

首先创建 2015 年 9 月 1 日至 10 月 30 日的预测日期范围，为每位艺人生成该时间段内的日期组合框架，确保每个艺人每天对应一条记录。接着从历史数据中提取艺人性别、语言等静态特征，关联到预测数据集，并计算星期几、月份、是否周末等时间特征。为处理模型输入，添加“unique_users”、“downloads”等缺失特征列并初始化为 0，同时为每位艺人提取截至 2015 年 8 月 30 日的最近 30 天历史数据，用于构建滞后特征、滚动窗口特征及变化率特征。对性别、语言等分类特征进行编码，填充缺失值后，确保所有模型所需特征列完整。

模型预测阶段，根据最优模型 LightGBM 进行预测，**对结果施加非负约束，并引入基于星期和月份的波动因子，叠加艺人特定的随机扰动（±10%）以模拟真实波动。随后按艺人和日期分组聚合，取平均值确保每天预测值唯一，并通过正弦函数添加基于日期的微小变化（<1%）避免重复**，最终保存结果到 CSV 文件。

为了更直观看出每个艺人未来 60 天每日播放量预测值的播放数据，我们还根据模型训练出的预测值结果，制作了不同艺术家预测播放量随时间变化图，如图 5 所示。

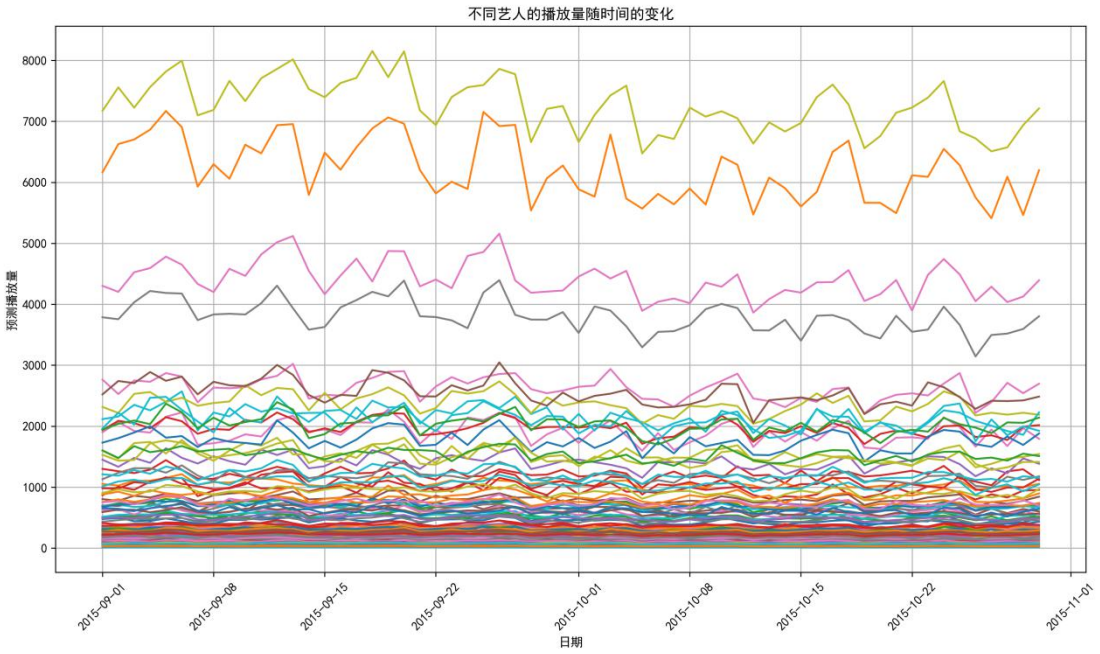


图 5 不同艺术家预测播放量随时间变化

在图中我们可以对比得出未来 60 天艺人的预测播放量的分布，可以发现仅有 4 位艺人的预测播放量在 3000 以上，大多数艺人的预测播放量在 3000 以下。

六、 模型的评价、改进与推广

6.1 模型的优点

（1）模型精度高

对模型都进行评估，从评估指标中反应其表现能力都不错。

（2）严谨合理

在建模过程中和求解模型时，存在结果一致性验证，表示其合理性；对数据处理严谨，考虑到异常值，确保模型后续预测可靠性。

（3）特征工程细致

构建了多维度的特征体系，特别是问题三中滞后特征和滑动窗口对时序预测至关重要。

6.2 模型的缺点

模型的数据主要基于音乐平台的数据，没有外部的影响因素。列如，社交媒体的热度，音乐奖项等。

6.3 模型的改进

当前模型依赖平台内部行为数据，改进方向应整合外部舆情数据，如社交媒体话题热度、搜索引擎指数，跨平台消费数据，如短视频 BGM 使用率、线下演唱会票房，通过图神经网络建模艺人、歌曲、用户的多维关系网络，解决数据孤岛问题使得模型更完整，提高预测准确，令其贴合实际可落地应用。打破静态特征局限，引入动态特征编码机制，将艺人静态属性转化为时间感知嵌入向量，使其随历史行为变化而动态调整。

6.4 模型的推广

本研究构建的音乐流行趋势预测模型体系，其核心在于提供了一套基于数据驱动、紧密结合业务约束的建模方法论。能为解决信息时代的流行度预测与资源优化问题提供了可复用的框架。未来的推广可结合具体场景进行特征适配、约束调整和模型优化。例如，应用于其商业决策，深化模型为评估版权价值动态评估工具，个人创作建议生成器以及艺人发展潜力及风险。

七、 参考文献

[1]秦林林.数据挖掘技术在音乐流行趋势预测中的应用研究[D].西南大学,2019.

[2]李堃,李猛,李艳玲,林民.基于LSTM-RPA音乐流行趋势预测研究[J].计算机工程与应用,2022,58(24):134-142.

[3]刘莹莹.基于线性规划模型的物流管理优化问题研究[J].销售与市场,2025,(02):91-93.

[4]王振业,叶成绪,王文韬,杨萍.基于LSTM-Att方法的音乐流行趋势预测[J].计算机技术与发展,2020,30(09):188-193.

[5]郁伟生,邓伟,张瑶,李蜀瑜.基于时间序列的音乐流行趋势预测研究[J].计算机工程与科学,2018,40(09):1703-1709.

[6]吴桂平,侯晓琴,王冰,周军,张艳,颜永红.基于艺人画像的歌曲点播量预测[J].网络新媒体技术,2017,6(03):20-26.

附录

1. 问题 1 和问题 2 模型.ipynb
2. 问题 3 模型.ipynb
3. 不同艺术家预测播放量随时间变化图（完整版）.png
4. 问题 2 结论的推荐数据.csv
5. 问题 3 结论每个艺人每日播放量预测值的播放数据.csv